LAPORAN PROJECT
DATA WAREHOUSE

Customer Shopping Trends Dataset

Kelompok 17

Shafa Rizqi Nur Wahidah	2409116
Fauzia Inanta Aurelia	2409116
Azhaar Athahiroh	2409116
Alvionej Resna Lawrend	2409116

Disusun untuk Memenuhi Tugas Mata Kuliah
Bussines Intelegence

Tools yang Digunakan:
Google Colab (Python & Pandas), PostgreSQL, Power BI

Univeristas Mulawarman Fakultas Teknik
Program Studi Sitem Informasi

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mendorong dunia bisnis untuk memanfaatkan data secara lebih strategis. Setiap transaksi yang terjadi dalam kegiatan perdagangan menyimpan informasi berharga yang apabila diolah dengan tepat, dapat menghasilkan wawasan bisnis yang mendalam dan mendukung pengambilan keputusan yang lebih baik.

Dalam konteks bisnis ritel dan e-commerce, memahami perilaku pelanggan merupakan kunci utama dalam merancang strategi pemasaran yang efektif. Namun, data transaksi yang besar dan kompleks seringkali sulit dianalisis secara langsung tanpa adanya infrastruktur data yang terstruktur. Oleh karena itu, diperlukan sebuah solusi berupa Data Warehouse yang mampu mengintegrasikan, menyimpan, dan menyajikan data dalam format yang mudah dianalisis.

Project ini membangun sebuah Data Warehouse berbasis dataset Customer Shopping Trends yang mencakup 3.900 transaksi dari 50 negara bagian Amerika Serikat. Dataset ini memuat informasi pelanggan, produk, musim, metode pembayaran, hingga frekuensi pembelian yang menjadi bahan analisis untuk menghasilkan insight bisnis yang relevan.

1.2 Tujuan Project

Project ini bertujuan untuk:

1. Membangun Data Warehouse dengan skema Star Schema yang terstruktur menggunakan PostgreSQL.
2. Melakukan proses ETL (Extract, Transform, Load) dari dataset CSV ke dalam database relasional.
3. Menganalisis data transaksi untuk menemukan pola dan tren pembelian pelanggan.
4. Menyajikan hasil analisis dalam bentuk dashboard interaktif menggunakan Power BI.
5. Mendokumentasikan seluruh proses project sebagai referensi akademik dan profesional.

1.3 Ruang Lingkup

Ruang lingkup project ini meliputi:

- Dataset: shopping_trends_updated.csv (3.900 baris, 18 kolom asli)
- Cakupan data: transaksi pelanggan di 50 negara bagian Amerika Serikat
- Tools: Google Colab, Python, Pandas, PostgreSQL, pgAdmin, Power BI
- Output: Database DW, file SQL, notebook Python, laporan, dan dashboard

1.4 Manfaat Project

Manfaat yang diharapkan dari project ini adalah:

- Akademis: Memberikan pemahaman praktis mengenai konsep Data Warehouse dan proses ETL.
- Bisnis: Menghasilkan insight yang dapat digunakan untuk strategi pemasaran dan pengembangan produk.
- Teknis: Membangun kompetensi dalam penggunaan tools analitik modern.

BAB II

PEMAHAMAN DATASET

2.1 Deskripsi Dataset

Dataset yang digunakan dalam project ini adalah Customer Shopping Trends Dataset yang bersumber dari platform Kaggle (https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset). Dataset ini merepresentasikan data transaksi retail fashion di Amerika Serikat dengan total 3.900 baris dan 18 kolom.

2.2 Struktur Kolom Dataset

No	Nama Kolom	Tipe Data	Deskripsi
1	Customer ID	Integer	ID unik pelanggan
2	Age	Integer	Usia pelanggan (tahun)
3	Gender	String	Jenis kelamin (Male/Female)
4	Item Purchased	String	Nama produk yang dibeli (25 jenis)
5	Category	String	Kategori produk (4 kategori)
6	Purchase Amount (USD)	Integer	Nilai transaksi dalam USD
7	Location	String	Negara bagian AS (50 state)
8	Size	String	Ukuran produk (S/M/L/XL)
9	Color	String	Warna produk (25 warna)
10	Season	String	Musim transaksi (4 musim)
11	Review Rating	Float	Rating ulasan pelanggan (1-5)
12	Subscription Status	String	Status langganan (Yes/No)
13	Shipping Type	String	Jenis pengiriman (6 jenis)
14	Discount Applied	String	Penerapan diskon (Yes/No)
15	Promo Code Used	String	Penggunaan kode promo (Yes/No)
16	Previous Purchases	Integer	Jumlah transaksi sebelumnya
17	Payment Method	String	Metode pembayaran (6 metode)
18	Frequency of Purchases	String	Frekuensi belanja (7 kategori)

2.3 Kondisi Kualitas Data

Hasil pemeriksaan kualitas data menunjukkan kondisi yang sangat baik:

- Missing Values: Tidak ditemukan nilai kosong pada seluruh 18 kolom (0%).
- Duplikasi: Tidak ditemukan baris data yang duplikat (0 baris).
- Konsistensi Nilai: Seluruh kolom kategorikal memiliki nilai yang konsisten tanpa typo.

- Tipe Data: Seluruh tipe data sudah sesuai dengan konten kolom masing-masing.

2.4 Insight Awal

Berdasarkan eksplorasi awal dataset, diperoleh beberapa temuan awal:

- Dataset merepresentasikan transaksi retail fashion yang mencakup seluruh 50 negara bagian AS.
- Terdapat 25 jenis produk fashion yang terbagi dalam 4 kategori utama.
- Transaksi tersebar merata di 4 musim dengan variasi nilai pembelian.
- Terdapat informasi lengkap terkait preferensi pelanggan, metode pembayaran, dan frekuensi belanja.

BAB III

DATA CLEANING & PREPROCESSING

3.1 Proses Cleaning

Meskipun dataset dalam kondisi bersih, beberapa transformasi tetap diperlukan untuk mempersiapkan data agar kompatibel dengan struktur Data Warehouse dan PostgreSQL.

3.2 Transformasi yang Dilakukan

3.2.1 Rename Kolom

Seluruh nama kolom dikonversi ke format snake_case agar kompatibel dengan PostgreSQL, menghilangkan spasi dan karakter khusus seperti tanda kurung.

3.2.2 Konversi Tipe Data Boolean

Kolom subscription_status, discount_applied, dan promo_code_used dikonversi dari format teks 'Yes'/'No' menjadi tipe Boolean (True/False) yang lebih efisien secara penyimpanan dan query.

3.2.3 Penambahan Kolom Turunan

Ditambahkan kolom-kolom baru sebagai hasil derivasi dari kolom yang sudah ada:

Kolom Baru	Sumber	Logika	Nilai
age_group	age	Kategorisasi usia	Teen / Young Adult / Adult / Middle Age / Senior
frequency_score	frequency_of_purchases	Konversi ke angka/tahun	1 (Annually) s/d 52 (Weekly)
revenue_segment	purchase_amount_usd	Segmentasi nilai transaksi	Low (<$30) / Medium ($30-$70) / High (>$70)
transaction_id	index	Primary key fact table	1 s/d 3900 (auto-generated)

3.3 Hasil Preprocessing

Setelah proses cleaning dan preprocessing, dataset memiliki 22 kolom (18 kolom asli + 4 kolom turunan) dengan 3.900 baris data. Data kemudian disimpan sebagai file shopping_trends_cleaned.csv sebagai input untuk proses ETL.

BAB IV

DESAIN DATA WAREHOUSE

4.1 Pendekatan Star Schema

Data Warehouse dalam project ini dirancang menggunakan pendekatan Star Schema. Star Schema merupakan model dimensional yang terdiri dari satu tabel fakta (fact table) sebagai pusat yang dikelilingi oleh beberapa tabel dimensi (dimension tables). Model ini dipilih karena kesederhanaan struktur, kemudahan query, dan performa yang optimal untuk keperluan analisis (OLAP).

4.2 Struktur Tabel

4.2.1 Fact Table — fact_sales

Tabel fakta menyimpan data transaksi beserta referensi ke semua tabel dimensi dan metric yang dapat diukur.

Kolom	Tipe Data	Keterangan
transaction_id	INT (PK)	Primary key transaksi
customer_id	INT (FK)	Referensi ke dim_customer
product_id	INT (FK)	Referensi ke dim_product
season_id	INT (FK)	Referensi ke dim_season
shipping_id	INT (FK)	Referensi ke dim_shipping
purchase_amount_usd	FLOAT	Nilai transaksi (metric)
review_rating	FLOAT	Rating ulasan (metric)
revenue_segment	VARCHAR	Segmentasi revenue (metric)

4.2.2 Dimension Tables

Tabel Dimensi	Primary Key	Jumlah Kolom	Jumlah Baris	Deskripsi
dim_customer	customer_id	9	3.900	Profil dan atribut pelanggan
dim_product	product_id	5	1.823	Detail produk (item, kategori, ukuran, warna)
dim_season	season_id	2	4	Informasi musim transaksi
dim_shipping	shipping_id	5	72	Detail pengiriman dan pembayaran

BAB V

ETL PROCESS

5.1 Gambaran Umum ETL

Proses ETL (Extract, Transform, Load) merupakan inti dari pembangunan Data Warehouse. Proses ini terdiri dari tiga tahap utama yang dilakukan secara berurutan.

5.2 Extract

Tahap Extract dilakukan di Google Colab dengan membaca file CSV menggunakan library Pandas. Dataset shopping_trends_updated.csv dimuat ke dalam DataFrame Python dengan fungsi pd.read_csv(). Pada tahap ini dilakukan pula pemeriksaan awal terhadap struktur data, jumlah baris, tipe data, missing values, dan duplikasi.

5.3 Transform

Tahap Transform mencakup seluruh proses pembersihan dan transformasi data sebagaimana dijelaskan pada Bab III. Selain itu, pada tahap ini dilakukan pembentukan tabel-tabel dimensi dan fakta melalui operasi seleksi kolom, drop_duplicates(), merge(), dan pemberian surrogate key (ID buatan).

Proses pembentukan fact_sales dilakukan dengan melakukan join (merge) antara DataFrame utama dengan seluruh tabel dimensi untuk mendapatkan foreign key yang sesuai:

- Merge dengan dim_product berdasarkan item_purchased, category, size, color.
- Merge dengan dim_season berdasarkan season.
- Merge dengan dim_shipping berdasarkan shipping_type, discount_applied, promo_code_used, payment_method.

5.4 Load

Mengingat keterbatasan koneksi jaringan antara Google Colab (server cloud Google) dan PostgreSQL yang berjalan di localhost laptop, pendekatan Load yang digunakan adalah melalui generate file SQL INSERT. Fungsi kustom df_to_insert_sql() digunakan untuk mengkonversi setiap DataFrame menjadi rangkaian perintah INSERT INTO yang valid.

File insert_data.sql yang dihasilkan kemudian diunduh dan dieksekusi langsung di pgAdmin. Pendekatan ini memiliki beberapa keunggulan:

- Tidak memerlukan koneksi langsung antara Colab dan PostgreSQL lokal.
- File SQL dapat disimpan sebagai dokumentasi dan dimasukkan ke repository GitHub.
- Proses dapat diulang kapan saja tanpa menjalankan ulang notebook Python.

5.5 Hasil ETL

Tabel	Jumlah Baris Terload	Status
dim_customer	3.900	Berhasil
dim_product	1.823	Berhasil
dim_season	4	Berhasil
dim_shipping	72	Berhasil
fact_sales	3.900	Berhasil

BAB VI

ANALISIS DATA

6.1 Analisis Produk

6.1.1 Produk Paling Laris

Berdasarkan hasil query terhadap Data Warehouse, distribusi transaksi antar produk bersifat sangat merata. Tiga produk teratas adalah Pants, Blouse, dan Jewelry dengan masing-masing 171 transaksi. Hal ini mengindikasikan bahwa bisnis tidak bergantung pada satu produk unggulan, melainkan memiliki portofolio produk yang seimbang.

Produk	Kategori	Transaksi	Total Revenue (USD)	Avg Rating
Pants	Clothing	171	$10.090	3.72
Blouse	Clothing	171	$10.410	3.68
Jewelry	Accessories	171	$10.010	3.76
Shirt	Clothing	169	$10.332	3.63
Dress	Clothing	166	$10.320	3.75

6.1.2 Revenue per Kategori

Kategori Clothing mendominasi revenue dengan kontribusi sebesar 44,5% dari total penjualan, diikuti Accessories (28,4%), Footwear (13,8%), dan Outerwear (7,1%).

Kategori	Transaksi	Total Revenue (USD)	Avg Spend	Avg Rating
Clothing	1.737	$104.264	$60.03	3.72
Accessories	1.240	$74.200	$59.84	3.77
Footwear	599	$36.093	$60.26	3.79
Outerwear	324	$18.524	$57.17	3.75

6.2 Analisis Tren Musiman

Analisis berdasarkan musim menunjukkan bahwa Fall (musim gugur) merupakan periode dengan revenue tertinggi ($60.018), sementara Summer (musim panas) menjadi periode dengan revenue terendah ($55.777). Temuan ini dapat digunakan sebagai dasar perencanaan stok dan strategi promosi musiman.

Musim	Total Transaksi	Total Revenue (USD)	Avg Spend
Fall	975	$60.018	$61.56
Spring	999	$58.679	$58.74
Winter	971	$58.607	$60.36

Musim	Total Transaksi	Total Revenue (USD)	Avg Spend
Summer	955	$55.777	$58.41

6.3 Segmentasi Pelanggan

6.3.1 Segmentasi Berdasarkan Usia

Segmen Middle Age (40-59 tahun) merupakan kelompok pelanggan paling dominan dengan 1.510 transaksi dan total revenue $89.741 (38,7% dari total). Segmen Young Adult (18-25 tahun) memiliki jumlah transaksi paling sedikit, namun memiliki average spending per transaksi yang cukup tinggi ($60.65).

Age Group	Usia	Transaksi	Total Revenue	Avg Spend
Middle Age	40–59 th	1.510	$89.741	$59.43
Adult	26–39 th	1.031	$61.816	$59.96
Senior	60+ th	788	$46.894	$59.51
Young Adult	18–25 th	571	$34.630	$60.65

6.3.2 Segmentasi Berdasarkan Gender

Pelanggan laki-laki mendominasi seluruh segmen usia. Segmen Male Middle Age merupakan segmen terbesar dengan 1.017 transaksi. Menariknya, Female Senior memiliki rata-rata spending tertinggi ($61.40 per transaksi), menjadikannya segmen premium yang potensial untuk produk bernilai tinggi.

6.4 Analisis Subscriber

Sebesar 73,2% dari total transaksi dilakukan oleh pelanggan non-subscriber (2.847 transaksi, $170.436 revenue), sementara pelanggan subscriber hanya berkontribusi 26,8%. Temuan ini mengindikasikan bahwa program subscription belum secara optimal mendorong loyalitas pelanggan dan perlu ditinjau kembali dari segi manfaat yang ditawarkan.

6.5 Analisis Pembayaran & Promosi

Keenam metode pembayaran yang tersedia (PayPal, Credit Card, Cash, Debit Card, Venmo, Bank Transfer) digunakan secara merata oleh pelanggan, menunjukkan fleksibilitas bisnis dalam menerima berbagai metode pembayaran. Lebih dari separuh transaksi (57,4%) terjadi tanpa diskon dan promo code, mengindikasikan loyalitas pelanggan yang tidak bergantung pada insentif harga.

BAB VII

VISUALISASI POWER BI

7.1 Koneksi ke PostgreSQL

Data Warehouse yang telah dibangun di PostgreSQL dihubungkan ke Power BI Desktop menggunakan koneksi native PostgreSQL. Seluruh lima tabel (1 fact table dan 4 dimension tables) diimport ke dalam Power BI dengan mode Import untuk performa optimal.

7.2 Model Relasi di Power BI

proses import, relasi antar tabel terbentuk secara otomatis berdasarkan foreign key yang telah didefinisikan. Relasi yang terbentuk adalah:

- fact_sales → dim_customer (via customer_id)
- fact_sales → dim_product (via product_id)
- fact_sales → dim_season (via season_id)
- fact_sales → dim_shipping (via shipping_id)

7.3 KPI Utama

KPI	Nilai	DAX Formula
Total Revenue	$233.081	SUM(fact_sales[purchase_amount_usd])
Total Transaksi	3.900	COUNT(fact_sales[transaction_id])
Avg Spend/Transaksi	$59.76	AVERAGE(fact_sales[purchase_amount_usd])
Avg Rating	3.75	AVERAGE(fact_sales[review_rating])
Subscriber Rate	27%	DIVIDE(COUNTROWS(FILTER(...TRUE())), COUNTROWS(...))

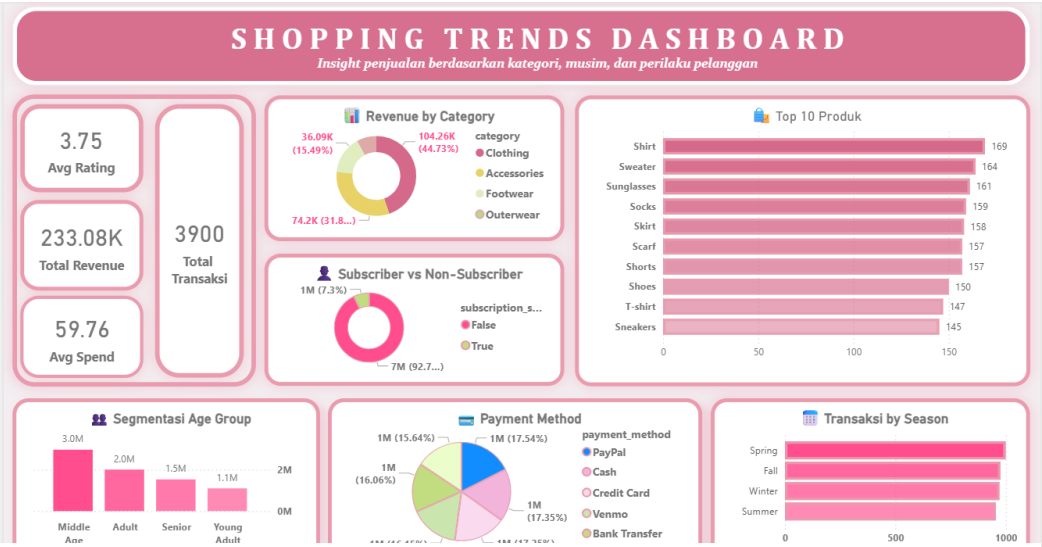

Gambar 1 Dashboard Shopping Trends

7.4 Struktur Dashboard

Dashboard Power BI dirancang dalam 3 halaman (pages) dengan fokus analisis yang berbeda:

- Page 1 Executive Summary: KPI cards, revenue per kategori (donut chart), transaksi per musim (bar chart), top 10 produk terlaris (horizontal bar).
- Page 2 Customer Segmentation: Revenue per age group, perbandingan gender per age group (stacked bar), subscriber vs non-subscriber (pie chart), avg spend per age group (line chart).
- Page 3 Transaction Analysis: Distribusi metode pembayaran, efek diskon dan promo (clustered bar), revenue per shipping type.

KESIMPULAN DAN SARAN

8.1 Kesimpulan

Berdasarkan seluruh tahapan project yang telah dilaksanakan, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Data Warehouse berhasil dibangun menggunakan Star Schema dengan 1 fact table (fact_sales) dan 4 dimension tables (dim_customer, dim_product, dim_season, dim_shipping) pada database PostgreSQL.
2. Proses ETL berhasil dilaksanakan sepenuhnya menggunakan Python (Pandas) di Google Colab dengan pendekatan generate file SQL sebagai solusi atas keterbatasan koneksi langsung ke PostgreSQL lokal.
3. Kategori Clothing merupakan kontributor revenue terbesar (44,5%), dengan Fall sebagai musim dengan penjualan tertinggi.
4. Segmen Middle Age (40-59 tahun) merupakan kelompok pelanggan paling dominan, sementara Female Senior memiliki rata-rata spending tertinggi per transaksi.
5. Program subscription belum optimal, dengan 73,2% transaksi berasal dari pelanggan non-subscriber.
6. Distribusi produk, metode pembayaran, dan penggunaan promo bersifat merata, mengindikasikan basis pelanggan yang beragam dan tidak terpusat pada satu preferensi.

8.2 Saran

Berdasarkan insight yang diperoleh dari analisis data, berikut beberapa saran yang dapat dipertimbangkan:

1. Tingkatkan benefit program subscription untuk mendorong lebih banyak pelanggan melakukan langganan dan meningkatkan loyalitas jangka panjang.
2. Fokuskan strategi pemasaran pada segmen Middle Age dan kembangkan lini produk premium untuk segmen Female Senior yang memiliki daya beli tinggi.
3. Perkuat stok dan promosi produk pada musim Fall sebagai peak season, serta rancang promosi khusus untuk mendongkrak penjualan di musim Summer.
4. Pertahankan diversifikasi produk yang merata sambil mengeksplorasi potensi produk Outerwear yang masih relatif kecil kontribusinya.
5. Untuk pengembangan project selanjutnya, dapat dipertimbangkan penambahan dimensi waktu (dim_date) untuk analisis tren yang lebih granular.